

Zeitschrift für

Sportpsychologie

Herausgeber

Henning Plessner
Rouwen Cañal-Bruland
Felix Ehrlenspiel
Petra Jansen
Julia Schüler
Karen Zentgraf

Organ der Arbeitsgemeinschaft für Sportpsychologie in Deutschland e. V.

Themenheft

Die „Vertrauenskrise“ der empirischen
Sozialwissenschaften und deren Bedeutung
für die Sportpsychologie

Inhalt

Editorial	Die „Vertrauenskrise“ der empirischen Sozialwissenschaften und deren Bedeutung für die Sportpsychologie	75
Positionspapiere	Die Vertrauenskrise empirischer Forschung in der Psychologie. Ausgewählte Ursachen und exemplarische Lösungsvorschläge für die sportpsychologische Forschung <i>The Crisis of Confidence in Psychological Research: Selected Causes and Suggestions for Research in Sport and Exercise Psychology</i> Geoffrey Schweizer und Philip Furley	77
	Wahres und Wissenswertes in der Sportpsychologie <i>Truth and Things Worth Knowing in Sport Psychology</i> Roland Seiler	84
	Die „Vertrauenskrise“ der empirischen Sozialwissenschaften und deren Bedeutung für die Sportpsychologie. Ein Kommentar aus der Perspektive der Vertrauensforschung <i>The “Trust Crisis” of Empiric Social Science and Its Meaning for Sport and Exercise Psychology: A Comment from the Trust Research Perspective</i> Dennis Dreiskämper	92
	Wege aus der Vertrauenskrise. Individuelle Schritte hin zu verlässlicher und offener Forschung <i>Ways Out of the Crisis of Confidence: Individual Steps Toward a Reliable and Open Science</i> Katharina Geukes, Felix D. Schönbrodt, Till Utesch, Sebastian Geukes und Mitja D. Back	99
Sportpsychologie-Digest	„Übung macht den Meister!“ – Auch im Hochleistungssport? Meta-analytische Betrachtung und Diskussion des Deliberate-Practice-Ansatzes <i>Lisa Musculus</i>	110
	Aufmerksamkeit – Jede Medaille hat zwei Seiten <i>Melanie Mack</i>	111
	Transkranielle Hirnstimulation in der Sportpsychologie <i>Nils Henrik Pix</i>	112
Nachrichten	Nachrichten aus der asp	113
Hinweise für Autoren		120

Zeitschrift für

Sportpsychologie

Ihr Artikel wurde in einer Zeitschrift des Hogrefe Verlages veröffentlicht. Wir freuen uns, diesen e-Sonderdruck der veröffentlichten Verlagsfassung für den persönlichen Gebrauch der Autoren, zur Weiterleitung an die Koautoren sowie zur Verwendung auf individuelle Nachfrage für private Zwecke und als Teil eines Forschungsantrages oder im Rahmen einer Abschluss- oder Doktorarbeit zur Verfügung zu stellen.

Sofern Sie Ihren Artikel auf einer persönlichen oder institutionellen Webseite, in einem institutionellen oder disziplinären Repository oder in wissenschaftlichen Netzwerken (scholarly communication networks, SCNs) hinterlegen möchten, verwenden Sie bitte die eingereichte Manuskriptfassung (vor peer review) oder die akzeptierte Manuskriptfassung (nach peer review) entsprechend den Richtlinien der Publikationsfreigabe für Ihren Artikel sowie den Nutzungsrichtlinien für Hogrefe-Zeitschriftenartikel (<http://hgf.io/nutzungsrichtlinien>).



Die Vertrauenskrise empirischer Forschung in der Psychologie

Ausgewählte Ursachen und exemplarische Lösungsvorschläge für die sportpsychologische Forschung

Geoffrey Schweizer¹ und Philip Furley²

¹ Institut für Sport und Sportwissenschaft, Universität Heidelberg

² Institut für Kognitions- und Sportspielforschung, Deutsche Sporthochschule Köln

Zusammenfassung: Ziel des vorliegenden Artikels ist es darzustellen, warum aktuell eine Vertrauenskrise der psychologischen Forschung postuliert wird. Wir beschreiben die Anzeichen der Vertrauenskrise bevor wir uns ihren mutmaßlichen Ursachen zuwenden: Researcher Degrees of Freedom, kleine Stichprobengrößen, Analyse- und Publikationspraktiken. Zusammen genommen haben diese Faktoren Anlass gegeben, die Reproduzierbarkeit psychologischer Forschung anzuzweifeln. Anschließend präsentieren wir ausgewählte Vorschläge, wie die Reproduzierbarkeit psychologischer Forschung erhöht werden kann. Mit dem vorliegenden Artikel möchten wir zu einer Forschungskultur innerhalb der Sportpsychologie beitragen, die geprägt ist von Reproduzierbarkeit, Transparenz und Vertrauen.

Schlüsselwörter: Methoden, Forschungspraktiken, Reproduzierbarkeit, Transparenz

The Crisis of Confidence in Psychological Research: Selected Causes and Suggestions for Research in Sport and Exercise Psychology

Abstract: We present the discussion on the crisis of confidence in psychological science. We first briefly describe what has led to this so-called crisis of confidence before outlining the assumed causes for the crisis: researcher degrees of freedom, small sample sizes, data analysis methods, and publication practices. In combination, these factors have led to justified doubts about the reproducibility of published research findings in psychology. Subsequently, we present suggestions to increase the reproducibility of research findings. With this article, we hope to contribute to a research culture of reproducibility, transparency, and trust within the field of sport and exercise psychology.

Keywords: methods, research practices, reproducibility, transparency

“At its core, this crisis is about the justification of knowledge. Researchers in the social and behavioral social sciences make claims that are simply unsupported by the methods they use.” (Hoekstra, Morey, Rouder & Wagenmakers, 2014, S. 1162)

Oben stehendes Zitat fasst prägnant eine Befürchtung zusammen, die seit einigen Jahren die Psychologie bewegt. Zahlreiche Autorinnen und Autoren postulieren eine tiefgehende Krise der empirischen psychologischen Forschung (z. B. Fraley & Vazire, 2014; Nosek & Lakens, 2014; Open Science Collaboration [OSC], 2012; in press; 2015; Pashler & Wagenmakers, 2012; Spellman, 2012). Andere Autorinnen und Autoren erkennen zwar Probleme an, hal-

ten die Ausrufung einer existenziellen Vertrauenskrise aber für überspitzt (Dijksterhuis, 2014; Fiedler, Kutzner & Krüger, 2012; Stroebe & Strack, 2014). Ziel des vorliegenden Artikels ist zunächst darzulegen, warum manche Autorinnen und Autoren von einer Vertrauenskrise sprechen und welche Gründe sie dafür haben¹. Daraufhin beschreiben wir kurz die aus unserer Perspektive wichtigsten Ansätze, um reproduzierbare Forschung sicher zu stellen (für eine ausführliche Darstellung möglicher Lösungsansätze siehe Geukes, Schönbrodt, Utesch, Geukes & Back, 2016, dieses Heft sowie OSC, in press). Wir hoffen, durch dieses Vorgehen zu einer weiteren Diskussion innerhalb der deutschsprachigen Sportpsychologie beitragen zu können.

¹ Die folgenden Überlegungen beziehen sich vor allem auf quantitative Forschungsansätze wie zum Beispiel korrelative Studien und Gruppenvergleiche, und nicht auf qualitative Forschungsansätze. Letztere spielen selbstverständlich ebenfalls eine bedeutende Rolle für den Erkenntnisgewinn in der sportpsychologischen Forschung, sie stehen jedoch nicht im Mittelpunkt der aktuellen Diskussion.

Die Vertrauenskrise

In den letzten Jahren mehren sich Artikel, die auf problematische Praktiken in der Planung, Durchführung, Auswertung und Interpretation psychologischer Studien hinweisen (Neuroskeptic, 2012; Simmons, Nelson & Simonsohn, 2011; Wagenmakers, Wetzels, Borsboom & van der Maas, 2011). Diese Praktiken führen zu falsch-positiven Resultaten bzw. Fehlern erster Art. Gleichzeitig wird deutlich, dass psychologische Befunde sich schlechter replizieren lassen als erwartet (z.B. Ebersole et al., 2015; OSC, 2015; Nosek & Lakens, 2014). In einem großangelegten Projekt zur Replikation von Befunden aus 100 Studien renommierter Zeitschriften konnten nur 39 % der ausgewählten Befunde repliziert werden (OSC, 2015). Nicht-erfolgreiche Replikationen können als Konsequenz von problematischen Forschungspraktiken verstanden werden. Zahlreiche Befunde lassen sich nicht replizieren, eben weil sie aufgrund der verwendeten Forschungspraktiken falsch-positive Ergebnisse darstellen. Die Krise der psychologischen Forschung ist somit primär eine Krise der Forschungspraktiken. Wagenmakers und Kollegen fassen diese Position prägnant zusammen (2011, S. 2): „... the field of psychology currently uses methodological and statistical strategies that are too weak, too malleable, and offer far too many opportunities for researchers to befuddle themselves and their peers.“ Aus dieser Perspektive bezieht sich der Begriff Vertrauenskrise (englisch „crisis of confidence“, z.B. Pashler & Wagenmakers, 2012) nicht auf schwindendes Vertrauen in andere Wissenschaftlerinnen und Wissenschaftler, sondern auf schwindendes Vertrauen in die Belastbarkeit der Ergebnisse psychologischer Forschung sowie auf schwindendes Vertrauen in die Methoden, mit denen diese Ergebnisse erzielt wurden (Wagenmakers et al., 2012).

Vorüberlegungen

Die meisten Effekte in der psychologischen Forschung sind vermutlich eher klein (OSC, 2015; Richard, Bond Jr & Stokes-Zoota, 2003). Gleichzeitig besteht sowohl erhebliche interindividuelle Variation (mehrere Menschen unterscheiden sich untereinander) als auch erhebliche intraindividuelle Variation (einzelne Menschen unterscheiden sich über die Zeit). Rein statistisch erschweren diese Umstände das Entdecken systematischer Zusammenhänge, in manchen Bereichen machen sie es sogar unmöglich (Gelman & Carlin, 2014; Gelman & Weakliem, 2009). Zu-

sätzlich erhöhen unreliable Messungen das Ausmaß zufälliger Variation und überdecken die ohnehin schwer zu identifizierenden systematischen Schwankungen (Stanley & Spence, 2014). Psychologische Theorien erlauben eher selten die Ableitung starker Hypothesen, wodurch sie einerseits Wissenschaftlerinnen und Wissenschaftlern wenig Orientierung bieten und andererseits resistent gegen eine Falsifizierung werden (Earp & Trafimow, 2015). Die oben beschriebene Umwelt hat scheinbar paradoxerweise zwei entgegengesetzte Konsequenzen: Zunächst ist es schwierig, tatsächliche systematische Variation innerhalb der zufälligen Variation zu entdecken. Daher gibt es vermutlich viele psychologische Regelmäßigkeiten oder Phänomene, die noch nicht entdeckt worden sind (Fiedler et al., 2012). Gleichzeitig ist es leicht, zufällige Variation fälschlicherweise für systematische zu halten. Daher werden vermutlich viele Effekte publiziert und Regelmäßigkeiten angenommen, die es in Wirklichkeit nicht gibt (Simmons et al., 2011; Wagenmakers et al., 2011). In der aktuellen Diskussion geht es vor allem um letztere Konsequenz: Welche Forschungspraktiken machen psychologische Forschung anfällig dafür, zufällige Variation für systematische zu halten?

Researcher Degrees of Freedom

Researcher Degrees of Freedom (RDF; etwa „Freiheitsgrade von Wissenschaftlerinnen und Wissenschaftlern“) beziehen sich auf Freiheiten, die Wissenschaftlerinnen und Wissenschaftler haben, wenn sie ihre Daten erheben, auswerten und berichten (Simmons et al., 2011). Beispielsweise könnten in einem Experiment drei Gruppen (zwei experimentelle Manipulationen sowie eine Kontrollgruppe), eine mögliche Kovariate, sowie zwei abhängige Variablen erhoben werden. In diesem Fall können die beteiligten Wissenschaftlerinnen und Wissenschaftler Entscheidungen treffen, wie die Daten ausgewertet werden sollen: Soll die Kovariate in die Analyse aufgenommen werden? Sollen alle drei Gruppen verglichen werden, oder nur die beiden experimentellen Gruppen? Welche der beiden abhängigen Variablen sollen ausgewertet werden? Derartige Flexibilität erhöht die Wahrscheinlichkeit eines Fehlers erster Art, wenn eigentlich die Nullhypothese zutrifft (Simmons et al., 2011).

Simmons und Kollegen führten Simulationen durch um exemplarisch den Einfluss verschiedener RDF auf den Fehler erster Art zu schätzen². Bereits die Wahl zwischen zwei abhängigen Variablen oder die Wahl zwischen

² Die Simulationen sind abhängig von verschiedenen Annahmen beispielsweise bezüglich des Designs, der Stichprobengröße oder der Korrelationen zwischen mehreren abhängigen Variablen (für Details siehe Simmons et al., 2011). Die Annahmen führen vermutlich zu eher konservativen Schätzungen des Anstiegs des Fehlers erster Art.

einer Auswertung mit oder ohne Kovariate verdoppeln in den Simulationen die Wahrscheinlichkeit eines Fehlers erster Art. Kombinationen mehrerer RDF erhöhen schnell die Wahrscheinlichkeit eines Fehlers erster Art von nominell 5 % auf bis zu 60,7 %. Je mehr RDF vorhanden sind bzw. genutzt werden, desto stärker steigt die Wahrscheinlichkeit eines Fehlers erster Art, oder wie Simmons und Kollegen bemerken (2011, S.1359): „In many cases, a researcher is more likely to falsely find evidence that an effect exists than to correctly find evidence that it does not ...“.

Einen besonders großen Einfluss auf die Wahrscheinlichkeit eines Fehlers erster Art hat das so genannte *p-hacking* (Sagarin, Ambler & Lee, 2014). Dies bezeichnet das Vorgehen, die Stichprobe schrittweise zu vergrößern, nach jeder Vergrößerung auf Signifikanz zu testen und bei einem signifikanten Ergebnis die Erhebung zu beenden.

Stichprobengrößen

Stichprobengrößen spielen aus verschiedenen Gründen eine Rolle. Erstens hängt die Teststärke oder Power einer Studie von der Stichprobengröße ab (Cohen, 1962; 1992). Das bedeutet, je größer eine Stichprobe, desto höher ist die Wahrscheinlichkeit einen Effekt zu finden, wenn es ihn tatsächlich gibt. Obwohl dieser Zusammenhang seit langer Zeit bekannt ist (z.B. Cohen, 1962), weisen psychologische Studien durchschnittlich immer noch eine eher geringe Teststärke auf (Bakker, van Dijk & Wicherts, 2012; Button et al., 2013; Fraley & Vazire, 2014; Schweizer & Furley, 2016; Sedlmeier & Gigerenzer, 1989). Bakker und Kolleginnen sowie Kollegen schätzen die mittlere Teststärke psychologischer Studien auf ungefähr .35 (2012), während Button und Kolleginnen sowie Kollegen die mittlere Teststärke in den Neurowissenschaften auf ungefähr .21 schätzen (2013)³. Schätzungen von Schweizer und Furley (2016) legen nahe, dass auch die Teststärke vieler sportpsychologischer Studien nicht ausreicht, um kleine bis mittlere Effekte zu finden. Geringe Teststärke *erhöht* also die Wahrscheinlichkeit, dass ein nicht-signifikantes Ergebnis einen Fehler zweiter Art darstellt (d.h., ein Effekt wurde nicht gefunden, obwohl es ihn tatsächlich gibt). Geringe Teststärke *senkt* gleichzeitig die Wahrscheinlichkeit, dass ein signifikantes Ergebnis einen wahren Effekt darstellt (d.h., geringe Teststärke erhöht die

Wahrscheinlichkeit eines falsch-positiven Ergebnisses). Es mag kontraintuitiv erscheinen, dass eine durchschnittlich geringe Teststärke in einem Studienbereich sowohl die Wahrscheinlichkeit für Fehler erster Art als auch für Fehler zweiter Art erhöht. Entscheidend ist hier das Konzept des Positive Predictive Value (PPV; Button et al., 2013; Ioannidis, 2005). Der PPV ist die Wahrscheinlichkeit, dass ein signifikanter Effekt einen wahren Effekt darstellt. Neben anderen Faktoren hängt der PPV von der Teststärke ab⁴. Je größer die durchschnittliche Teststärke in einem Studienbereich, desto höher ist die Wahrscheinlichkeit, dass ein berichteter Effekt einen wahren Effekt darstellt.

Kleine Stichproben erhöhen nicht nur die Wahrscheinlichkeit eines Fehlers erster oder zweiter Art, sondern sie führen auch zur Überschätzung von Effektgrößen (Button et al., 2013; Ioannidis, 2005). Effekte, die in kleinen Stichproben gefunden wurden, sind wahrscheinlich größer als der zugrunde liegende „wahre Effekt“, falls es ihn gibt. Der Grund dafür ist, dass Effekte zufällig variieren. Je kleiner eine Stichprobe, desto größer ist der Einfluss einiger weniger starker Variationen. Gleichzeitig überschreiten bei kleinen Stichproben nur große Effekte die Signifikanzschwelle. Wenn Effekte eine bestimmte Schwelle überschreiten müssen, um als Entdeckung zu gelten, dann werden Studien mit Effekten, die den wahren Effekt überschätzen publiziert, während Studien mit Effekten, die den wahren Effekt unterschätzen nicht publiziert werden. Dieses Phänomen wird auch „winner’s curse“ (etwa „der Fluch des Siegers“) genannt (Button et al., 2013). Wird ein bestimmtes Thema anhand einer Vielzahl von Studien mit jeweils kleinen Stichproben beforscht, dann ist zu erwarten, dass die verschiedenen Studien zu stark unterschiedlichen Ergebnissen hinsichtlich der Größe und sogar Richtung von Effekten kommen.

Schließlich sind kleine Stichproben problematisch, wenn es um die Replikation von Ergebnissen geht. Wenn ein publizierter Effekt aus einer Studie mit einer kleinen Stichprobe herangezogen wird, um die Stichprobengröße für den Replikationsversuch zu bestimmen, und dieser publizierte Effekt überschätzt den wahren Effekt, dann kann er beim Replikationsversuch nicht gefunden werden, weil die Stichprobe der Replikationsstudie zu klein ist. In der Konsequenz gilt der Effekt als nicht repliziert. In Wirklichkeit mag es ihn jedoch geben, er ist nur kleiner als erwartet. Es scheint beinahe unmöglich, die Bedeutung angemessener Stichprobengrößen für die quantitative

³ Schätzungen der Teststärke auf Basis von Stichprobengrößen sind abhängig von Annahmen bezüglich des Designs und bezüglich der durchschnittlichen Effektgröße. Bakker und Kolleginnen sowie Kollegen beispielsweise beziehen ihre Schätzungen auf einen Effekt $d = .5$ und einen Vergleich zweier unabhängiger Stichproben (2012).

⁴ Für eine genaue Erklärung, warum kleine Stichproben zu einem höheren Anteil an falsch-positiven Ergebnissen führen siehe Ioannidis (2005), Button et al. (2013) oder Wagenmakers et al. (2015).

Forschung zu überschätzen. Manche Autorinnen und Autoren sehen zu kleine Stichproben als das zentrale Problem der psychologischen Forschung, das sowohl inkonsistente Befunde als auch fehlgeschlagene Replikationen erklärt (Fraley & Vazire, 2014):

“It is possible that the so-called *replication crisis* or *crisis of confidence* in psychology is an artifact of a long history of researchers using under-powered designs – a state of affairs that is guaranteed to reduce the odds that published findings can be replicated.” (Fraley & Vazire, 2014, S. 4)

Publikationsbias und File Drawer

Seit langem wird das akademische Publikationssystem kritisiert, weil positive Befunde (das Finden eines hypothesenkonformen Ergebnisses) leichter publiziert werden können als negative Befunde (Nullbefunde oder hypothesenkonträre Ergebnisse). Dieser Zustand wird auch als Publikationsbias oder „File Drawer“ bezeichnet (Francis, 2012). Problematische Forschungspraktiken wie RDF oder kleine Stichproben entfalten erst in Zusammenhang mit dem Publikationsbias ihre Wirkung voll. Wenn hypothesenkonforme Befunde leichter publiziert werden können als andere, dann steigt der Anreiz RDF zu nutzen, um derartige Befunde zu erhalten. Besonders problematisch erscheint der Publikationsbias in Zusammenhang mit kleinen Stichproben: Wenn alle Ergebnisse, die anhand kleiner Stichproben erzielt wurden publiziert würden, dann würde zwar eine große Anzahl an Effekten publiziert werden, die mehr oder weniger stark vom wahren Effekt abweichen. Die publizierte Literatur wäre aber nicht in eine bestimmte Richtung verzerrt. Erst wenn aufgrund des Publikationsbias nur große Effektgrößen oder hypothesenkonforme Ergebnisse publiziert werden können, wird die bestehende Literatur systematisch verzerrt. Wie Simmons und Kollegen zeigen (2011) wird die kombinierte Wirkung von Publikationsbias, RDF und kleinen Stichproben häufig unterschätzt: Wenn viele Studien mit kleinen Stichproben und RDF durchgeführt und selektiv nur die publiziert werden, die einen Effekt finden, dann können hunderte Studien publiziert werden, die Evidenz für einen Effekt präsentieren, obwohl es ihn in Wirklichkeit nicht gibt. RDF und kleine Stichproben lassen daher auch den Nutzen von Metaanalysen fraglich erscheinen (z. B. van Elk et al., 2015). Wenn aufgrund von RDF und kleinen Stichproben der Input in eine Metaanalyse verzerrt ist, dann wird sich diese Verzerrung auch im Output der Metaanalyse widerspiegeln. Zwar wird in der Regel versucht, eine solche Verzerrung durch die Aufnahme nicht publizierter Studien abzumildern. In welchem Ausmaß dies gelingt ist jedoch zweifelhaft.

Maßnahmen zur Erhöhung der Reproduzierbarkeit von Forschungsergebnissen

Die Open Science Collaboration hat Maßnahmen vorgeschlagen um das Vertrauen in die Ergebnisse psychologischer Forschung zurück zu gewinnen (OSC, in press). Die vorgeschlagenen Maßnahmen beinhalten den Umgang mit den Kernproblemen RDF und Stichprobengrößen, gehen jedoch darüber hinaus. Der Fokus der OSC liegt auf der grundsätzlichen Reproduzierbarkeit psychologischer Studien sowie auf Transparenz. Die Vorschläge der OSC sind detailliert und beziehen sich auf verschiedene Phasen des Forschungs- und Publikationsprozesses, von der Projektplanung über Projektdurchführung, Datenauswertung und Veröffentlichung bis hin zur Begutachtung von Manuskripten und Konzipierung von Forschungsstrategien. Die vorgeschlagenen Maßnahmen sollen eine handhabbare Möglichkeit für einzelne Wissenschaftlerinnen und Wissenschaftler darstellen, um eine Wende hin zur Transparenz und Reproduzierbarkeit einzuleiten, ohne jedoch in der gegenwärtigen wissenschaftlichen Kultur unterzugehen (OSC, in press).

Es ist uns ein Anliegen zu betonen, dass die aktuelle Diskussion sich keinesfalls darauf beschränkt, vermeintliche Missstände und Probleme zu benennen, sondern ganz im Gegenteil eine Vielzahl konkreter Lösungsvorschläge sowie technischer Möglichkeiten zu deren Umsetzung vorgestellt werden. Wir verzichten an dieser Stelle auf eine detaillierte Vorstellung möglicher Lösungsvorschläge, da sie im Beitrag „Wege aus der Vertrauenskrise“ von Geukes und Kollegen (2016, dieses Heft) beschrieben werden. Unseres Erachtens gibt es jedoch unter allen Lösungsvorschlägen drei Kernkomponenten, deren Umsetzung entscheidend ist um das möglicherweise verloren gegangene Vertrauen in die psychologische Forschung zurück zu gewinnen beziehungsweise für die Zukunft sicher zu stellen. Es handelt sich dabei um die Durchführung von Studien mit einer angemessenen Teststärke, die Vermeidung von RDF und die Trennung exploratorischer und konfirmatorischer Analysen.

Studien mit angemessener Teststärke

Eine Methode die Teststärke zu erhöhen besteht darin, die Stichprobe der Studienteilnehmerinnen und Studienteilnehmer zu vergrößern (siehe Faul, Erdfelder, Lang & Buchner, 2007, für die Bestimmung von optimalen Stichprobengrößen). Allerdings gibt es weitere Strategien, welche es erlauben die Teststärke zu erhöhen ohne die Stichprobe zu vergrößern. Für einige Forschungsfragen

können *within-subject* Designs und Messwiederholungen eingesetzt werden. Diese Designs haben eine wesentlich höhere Teststärke als *between-subject* Designs, da sie es erlauben die getesteten Studienteilnehmerinnen und Studienteilnehmer als eigene Kontrollgruppe zu verwenden und somit unsystematische Varianz in den Daten zu reduzieren. Weiterhin erhöhen experimentelle Manipulationen die Teststärke (im Vergleich zu quasi-experimentellen und korrelativen Designs), da sie konfundierende Einflussfaktoren minimieren. Die Verwendung von reliablen abhängigen Variablen trägt ebenfalls zur Erhöhung der Teststärke bei, da somit der Messfehler reduziert wird. Zu guter Letzt kann die Teststärke erhöht werden, indem die unsystematische Varianz durch das Standardisieren von Studienprotokollen minimiert wird, da alle Studienteilnehmerinnen und Studienteilnehmer nahezu identische Bedingungen haben. Da die Publikation von Studien mit hoher Teststärke mehr Zeit in Anspruch nehmen wird, wird dadurch vermutlich insgesamt weniger publiziert. Dafür steigen die Chancen, reproduzierbare Ergebnisse zu erhalten.

Ein ergänzender Ansatz um Studien mit einer hohen Teststärke durchzuführen ist die Kollaboration mit Kolleginnen und Kollegen sowie anderen Arbeitsgruppen. Wenn eine einzelne Arbeitsgruppe nicht genügend Studienteilnehmerinnen und Studienteilnehmer testen kann, um ausreichende statistische Teststärke zu haben, könnte das Hinzuziehen weiterer Arbeitsgruppen Abhilfe schaffen. So könnten alle Arbeitsgruppen das gleiche Design und die gleichen Materialien verwenden und anschließend die Daten in einem einzigen Test aggregieren, um eine Forschungsfrage zuverlässig zu beantworten.

Vermeidung von Researcher Degrees of Freedom

Wissenschaftlerinnen und Wissenschaftler stehen vor einer Vielzahl an wichtigen Entscheidungen (siehe Beispiel unter Researcher Degrees of Freedom), wenn sie eine Forschungsfrage beantworten wollen und hierfür Daten erheben und auswerten. Um diese Problematik nochmals zu verdeutlichen analysierte Carp (2012a) 241 publizierte fMRI Studien und kam zu dem Schluss, dass es 223 individuelle Kombinationsmöglichkeiten gab die Daten zu bereinigen und zu analysieren. Carp (2012b) geht noch einen Schritt weiter und argumentiert, dass diese Freiheitsgrade es Neurowissenschaftlerinnen und -wissenschaftlern erlaubt die Daten so lange beliebig zu analysieren bis das gewünschte Ergebnis erreicht ist. Im Speziellen konnte gezeigt werden, dass Analyseentscheidungen derartig viele Kombinationsmöglichkeiten bieten, dass es möglich war bei der Analyse einer einzigen fMRI Studie in 90.3 % der

Gehirn Voxel signifikante Unterschiede zwischen den experimentellen Bedingungen zu zeigen (Carp, 2012b).

Hieraus folgt, dass die Reduktion der Freiheitsgrade, die Wissenschaftlerinnen und Wissenschaftler bei der Durchführung und Analyse einer Studie haben, ein entscheidender Schritt sein muss, um sich gegen Fehler erster Art abzusichern. Eine vorgeschlagene Lösung hierfür ist die a priori Dokumentation der Studie. Dies bedeutet, dass Wissenschaftlerinnen und Wissenschaftler bevor sie eine Studie beginnen, dokumentieren wie die Daten ausgewertet werden. Darin besteht für Wagenmakers, Wetzels, Borsboom, van der Maas und Kievit (2012) die Essenz von konfirmatorischer Forschung. Sie gewährleistet, dass Signifikanzwerte die Bedeutung behalten, die sie eigentlich tragen: Der p-Wert gibt die Wahrscheinlichkeit an, dass diese Daten aufgetreten wären, wenn es eigentlich keinen Effekt gäbe. Darüber hinaus erlaubt das Vorgehen der a priori Veröffentlichung der Analyseverfahren die Trennung zwischen exploratorischer Forschung und konfirmatorischer Forschung. Wenn vorab nicht klar ist wie Daten analysiert werden, sollte zunächst in Pilotstudien geklärt werden wie eine konfirmatorische Studie konstruiert sein müsste, um eine Hypothese zu überprüfen (Wagenmakers et al, 2012).

Trennung exploratorischer und konfirmatorischer Analysen

Exploratorische Forschung kann einen wertvollen Beitrag zur Erkenntnisgewinnung leisten (Tukey, 1977), und viele wichtige wissenschaftliche Befunde wurden durch beiläufige Beobachtungen gemacht. Daher soll hier nicht das Missverständnis entstehen, dass konfirmatorische Forschung exploratorischer Forschung stets vorzuziehen sei. Vielmehr soll hervorgehoben werden, dass die Ergebnisse von exploratorischer Forschung explizit von denen der konfirmatorischen Forschung unterschieden werden sollten.

In diesem Zusammenhang hat Popper (1959) argumentiert, dass eine Hypothese, welche sich aus einer definierten Beobachtungsreihe herauskristallisiert hat, nicht mit der gleichen Beobachtungsreihe falsifiziert werden kann: „... a hypothesis can only be empirically tested – and only after it has been advanced“ (p. 7). Daher ist die Unterscheidung zwischen exploratorischer und konfirmatorischer Forschung zielführend, da sie nahelegt, dass exploratorische Analysen weitere empirische Studien benötigen.

Wenn man eine (beiläufige) Entdeckung gemacht hat, kann man die Versuchung nachvollziehen diese Entdeckung schnellst möglich publizieren zu wollen. Eine empirische Überprüfung bzw. Replikation der Entdeckung birgt das Risiko den entdeckten Effekt zu „verlieren“ (Nosek, Spies & Motyl, 2012) oder, dass jemand anderes den Effekt

vorher publiziert. Vermutlich gibt es für dieses Dilemma keine einfache Lösung, außer darauf hinzuweisen, dass exploratorische Ergebnisse die Möglichkeit eröffnen Hypothesen zu testen, jedoch nicht als eigenständige Hypothesentests angesehen werden dürfen. Langfristig gesehen ist es besser schnell zu lernen, dass ein Effekt nicht reproduzierbar ist als die eigenen und die Ressourcen anderer Wissenschaftlerinnen und Wissenschaftler mit eventuellen Folgestudien zu verschwenden, die auf der Prämisse beruhen, dass der Effekt existiert. Daher scheint der sinnvollste Weg eine exploratorische Entdeckung mit einer konfirmatorischen Studie, die eine hohe Teststärke hat, zu testen.

Abschließende Diskussion zur Bedeutung für die Sportpsychologie

Ziel dieses Beitrages ist, die Diskussion zur sogenannten Vertrauenskrise in die Sportpsychologie einzuführen. Darüber hinaus weisen wir auf erste Maßnahmen hin, die geeignet sein könnten, eine hohe Reproduzierbarkeit sportpsychologischer Forschung zu gewährleisten. Dieses Manuskript soll zu einer Kultur der Reproduzierbarkeit, der Transparenz und des vertrauensvollen Miteinanders in dem Forschungsfeld Sportpsychologie beitragen. Wir halten reproduzierbare Forschung in einem anwendungsbezogenen Feld wie der Sportpsychologie für besonders wichtig, da hier Forschungsergebnisse relativ zügig in die Praxis transferiert werden (siehe zum Beispiel Stroebe & Strack [2014] für eine Abwägung der Bedeutung replizierbarer Ergebnisse in der Grundlagenforschung im Vergleich zur anwendungsorientierten Forschung). Wenn manche dieser Ergebnisse allerdings nicht belastbar sind, dann könnten beispielsweise Athletinnen und Athleten darunter leiden, da sie falsch trainiert, gecoacht oder betreut würden. Daher sollte Zuverlässigkeit und Reproduzierbarkeit einen herausragenden Stellenwert in dem anwendungsbezogenen Forschungsfeld Sportpsychologie haben. Wir betrachten die Empfehlungen der OSC (Geukes et al., 2016, dieses Heft; OSC, in press) als Vorschläge, die selbstverständlich Vor- und Nachteile haben (z.B. Fiedler et al., 2012). Eine detaillierte Diskussion aller möglichen Nachteile würde den Rahmen dieses Artikels sprengen. Wir hoffen jedoch, mit diesem Artikel zu einer offenen Diskussion der Vertrauenskrise sowie der vorgeschlagenen Ansätze mit allen Vorteilen und Nachteilen beitragen zu können. Erst als Resultat dieser Diskussion wird sich zeigen, welche Vorschläge weitgehend angenommen werden und welche nicht.

In einer vielzitierten Rede vom 11. Nov. 1947 hat der britische Staatsmann Winston Churchill behauptet: „De-

mocracy is the worst form of government, except for all those other forms that have been tried from time to time.“ Ähnlich sehen wir es mit der wissenschaftlichen Methode der Erkenntnisgewinnung. Sicherlich hat diese Methode ihre Schwächen und es muss häufig viel Aufwand betrieben werden, um lediglich „kleine“ Erkenntnisse zuverlässig zu gewinnen. Allerdings scheint es bislang keine bessere Methode zur Erkenntnisgewinnung zu geben und wir sind nicht der Meinung, dass die wissenschaftliche Methode der Erkenntnisgewinnung auf Grund der sogenannten Vertrauenskrise grundsätzlich in Frage gestellt werden sollte. Ohne grundlegende Änderungen in der wissenschaftlichen Praxis der Erkenntnisgewinnung zu postulieren sind wir jedoch der Meinung, dass eine Auseinandersetzung mit den Ursachen der postulierten Vertrauenskrise sowie mit den Vorschlägen zu ihrer Lösung (Geukes et al., 2016, dieses Heft; OSC, in press) einen wichtigen Beitrag leisten kann, um die Reproduzierbarkeit von sportpsychologischer Forschung zu erhöhen.

Grundsätzlich gibt es momentan keine direkte Evidenz, dass die meisten, oder auch nur einige, Studien im Bereich der Sportpsychologie falsch sind. Allerdings legt der Befund der mangelnden Reproduzierbarkeit psychologischer Forschung (OSC, 2015) nahe, dass das anwendungsbezogene Feld der Sportpsychologie nur davon profitieren kann diese Diskussion ernst zu nehmen, um sicherzustellen, dass die gewonnen Erkenntnisse auch reproduzierbar und somit zuverlässig sind. Zuletzt möchten wir darauf hinweisen, dass der Fokus auf Reproduzierbarkeit von Studien nicht auf Kosten von Innovation und Originalität gehen sollte, da beide wichtige Kriterien für wissenschaftlichen Fortschritt darstellen: „Innovation points out paths that are possible; replication points out paths that are likely; progress relies on both“ (OSC, 2015). In diesem Sinne freuen wir uns auf zukünftige, innovative und reproduzierbare Forschung in dem faszinierenden Forschungsfeld der Sportpsychologie.

Literatur

- Bakker, M., van Dijk, A. & Wicherts, J. M. (2012). The rules of the game called psychological science. *Perspectives on Psychological Science*, 7, 543 – 554. doi: 10.1177/1745691612459060
- Button, K. S., Ioannidis, J. P. A., Mokrysz, C., Nosek, B. A., Flint, J., Robinson, E. S. J. & Munafò, M. R. (2013). Power failure: Why small sample sizes undermine the reliability of neuroscience. *Nature Reviews Neuroscience*, 14, 365 – 376. doi: 10.1038/nrn3475
- Carp, J. (2012a). The secret lives of experiments: Methods reporting in the fMRI literature. *NeuroImage*, 63, 289 – 300. doi: 10.1016/j.neuroimage.2012.07.004
- Carp, J. (2012b). On the plurality of (methodological) worlds: Estimating the analytic flexibility of fMRI experiments. *Frontiers in Neuroscience*, 6, 149. doi: 10.3389/fnins.2012.00149

- Cohen, J. (1962). The statistical power of abnormal-social psychological research: A review. *Journal of Abnormal Social Psychology*, 65, 145 – 153. doi: 10.1037/h0045186
- Cohen, J. (1992). A power primer. *Psychological Bulletin*, 112, 155 – 159. doi: 10.1037/0033-2909.112.1.155
- Dijksterhuis, A. (2014). Welcome back theory! *Perspectives on Psychological Science*, 9, 71 – 75.
- Ebersole, C. R., Atherton, O. E., Belanger, A. E., Skulborstad, H. M., Allen, J. M., Banks, J. B., et al. (2015). *Many Labs 3: Evaluating participant pool quality across the academic semester via replication*. Retrieved from <https://osf.io/s59bg/>
- Earp, B. D. & Trafimow, D. (2015). Replication, falsification, and the crisis of confidence in social psychology. *Frontiers in Psychology*, 6, 621. doi: 10.3389/fpsyg.2015.00621
- Faul, F., Erdfelder, E., Lang, A. G. & Buchner, A. (2007). G* Power 3: A flexible statistical power analysis program for the social, behavioral, and biomedical sciences. *Behavior Research Methods*, 39, 175 – 191. doi: 10.3758/BF03193146
- Fiedler, K., Kutzner, F. & Krüger, J. I. (2012). The long way from α -error control to validity proper: Problems with a short-sighted false-positive debate. *Perspectives on Psychological Science*, 7, 661 – 669.
- Friley, R. C. & Vazire, S. (2014). The N-Pact Factor: Evaluating the quality of empirical journals with respect to sample size and statistical power. *PLoS One*, 9, e109019. doi: 10.1371/journal.pone.0109019
- Francis, G. (2012). Publication bias and the failure of replication in experimental psychology. *Psychonomic Bulletin and Review*, 19, 975 – 991. doi: 10.3758/s13423-012-0322-y
- Gelman, A. & Carlin, J. (2014). Beyond power calculations: Assessing Type S (Sign) and Type M (Magnitude) errors. *Perspectives on Psychological Science*, 9, 641 – 651. doi: 10.1177/1745691614551642
- Gelman, A. & Weakliem, D. (2009). Of beauty, sex, and power. Too little attention has been paid to the statistical challenges in estimating small effects. *American Scientist*, 97, 310 – 316.
- Geukes, K., Schönbrodt, F. D., Utesch, T., Geukes, S. & Back, M. D. (2016). Wege aus der Vertrauenskrise. Individuelle Schritte hin zu verllässlicher und offener Forschung. *Zeitschrift für Sportpsychologie*, 23, 99 – 109.
- Hoekstra, R., Morey, R. D., Rouder, J. N. & Wagenmakers, E.-J. (2014). Robust misinterpretation of confidence intervals. *Psychonomic Bulletin & Review*, 21, 1157 – 1164.
- Ioannidis, J. P. A. (2005). Why most published research findings are false. *PLoS Medicine*, 2, e124.
- Neuroskeptic (2012). The nine circles of scientific hell. *Perspectives on Psychological Science*, 7, 643 – 644.
- Nosek, B. A. & Lakens, D. (Eds.) (2014). Replications of important results in social psychology [Special issue]. *Social Psychology*, 45. doi: 10.1027/1864-9335/a000192
- Nosek, B. A., Spies, J. R. & Motyl, M. (2012). Scientific Utopia: II. Restructuring incentives and practices to promote truth over publishability. *Perspectives on Psychological Science*, 7, 615 – 631. doi: 10.1177/1745691612459058
- Open Science Collaboration (2012). An open, large-scale, collaborative effort to estimate the reproducibility of psychological science. *Perspectives on Psychological Science*, 7, 657 – 660. doi: 10.1177/1745691612462588
- Open Science Collaboration (in press). Maximizing the reproducibility of your research. In S. O. Lilienfeld & I. D. Waldman (Hrsg.), *Psychological Science Under Scrutiny: Recent Challenges and Proposed Solutions*. New York, NY: Wiley.
- Open Science Collaboration. (2015). Estimating the reproducibility of psychological science. *Science*, 349, aac4716. doi: 10.1126/science.aac4716
- Pashler, H. & Wagenmakers, E.-J. (Eds.). (2012). Special section on replicability in psychological science: A crisis of confidence? [Special section]. *Perspectives on Psychological Science*, 7, 528 – 654. doi: 10.1177/1745691612465253
- Popper, K. R. (1959). *The Logic of scientific discovery*. London: Hutchinson.
- Richard, F. D., Bond Jr, C. F. & Stokes-Zoota, J. J. (2003). One hundred years of social psychology quantitatively described. *Review of General Psychology*, 7, 331 – 363. doi: 10.1037/1089-2680.7.4.331
- Sagarin, B. J., Ambler, J. K. & Lee, E. M. (2014). An ethical approach to peeking at data. *Perspectives on Psychological Science*, 9, 293e304. doi: 10.1177/1745691614528214
- Schweizer, G. & Furley, P. (2016). Reproducible research in sport and exercise psychology: The role of sample sizes. *Psychology of Sport and Exercise*, 23, 114 – 122. doi: 10.1016/j.psychsport.2015.11.005
- Sedlmeier, P. & Gigerenzer, G. (1989). Do studies of power have an effect on the power of studies? *Psychological Bulletin*, 105, 309 – 316. doi: 10.1037/0033-2909.105.2.309
- Simmons, J. P., Nelson, L. D. & Simonsohn, U. (2011). False-Positive Psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science*, 22, 1359 – 1366.
- Spellman, B. A. (Ed.). (2012). Special section on research practices [Special section]. *Perspectives on Psychological Science*, 7, 655 – 689. doi: 10.1177/1745691612465075
- Stanley, D. J. & Spence, J. R. (2014). Expectations for replications: Are yours realistic? *Perspectives on Psychological Science*, 9, 305 – 318.
- Stroebe, W. & Strack, F. (2014). The alleged crisis and the illusion of exact replication. *Perspectives on Psychological Science*, 9, 59 – 71.
- Tukey, J. W. (1977). *Exploratory data analysis*. Reading, MA: Addison-Wesley.
- van Elk, M., Matzke, D., Gronau, Q. F., Guan, M., Vandekerckhove, J. & Wagenmakers, E.-J. (2015). Meta-analyses are no substitute for registered replications: A skeptical perspective on religious priming. *Frontiers in Psychology*, 6, 1365.
- Wagenmakers, E.-J., Verhagen, A. J., Ly, A., Bakker, M., Lee, M. D., Matzke, D., Rouder, J. N. & Morey, R. D. (2015). A power fallacy. *Behavior Research Methods*. doi: 10.3758/s13428-014-0517-4
- Wagenmakers, E.-J., Wetzels, R., Borsboom, D. & van der Maas, H. L. J. (2011). Why psychologists must change the way they analyze their data: The case of psi: Comment on Bem (2011). *Journal of Personality and Social Psychology*, 100, 426 – 432.
- Wagenmakers, E.-J., Wetzels, R., Borsboom, D., van der Maas, H. L. & Kievit, R. A. (2012). An agenda for purely confirmatory research. *Perspectives on Psychological Science*, 7, 632 – 638. doi: 10.1177/1745691612463078

Geoffrey Schweizer

Universität Heidelberg
Institut für Sport und Sportwissenschaft
Im Neuenheimer Feld 700
69120 Heidelberg
geoffrey.schweizer@issw.uni-heidelberg.de

Philip Furley

Deutsche Sporthochschule Köln
Institut für Kognitions- und Sportspielforschung
Am Sportpark Müngersdorf 6
50933 Köln